


# GUÍA DE APRENDIZAJE Nº 1: DATOS, INFORMACIÓN, TOMA DE DECISIONES, FUENTES Y FORMATOS

Juana Virgelina Corrales Rico

Laura Natalia Becerra Tirano

Braian Isaak Patarroyo De Castro

Servicio Nacional de Aprendizaje (SENA)

Trimestre I - Ficha: 3602991

## Actividades para Desarrollar

- Documentar de manera concisa las diferencias estructurales entre un archivo de texto plano (CSV), un formato de hoja de cálculo heredado (XLS) y uno moderno (XLSX), haciendo énfasis en sus límites de almacenamiento (filas y columnas) e identificando en qué punto exacto falló la integridad de los datos en el caso expuesto.
- Elaborar un esquema conceptual que ilustre cómo debió ser el tránsito seguro de la información desde los laboratorios (origen) hasta el tablero de control gubernamental (destino). Se debe justificar qué formatos (CSV o XLS) debieron emplearse en cada etapa para garantizar la preservación de los casi 16.000 registros perdidos.
- Redactar una conclusión analítica sobre la relación directa entre el conocimiento técnico del analista de datos y la responsabilidad ética en la toma de decisiones a nivel gerencial o gubernamental.

## Actividad 1: Diferencias Estructurales CSV vs. XLS vs. XLSX y Análisis de Fallo

**Tabla 1**

*Resumen Comparativo de Formatos de Archivos de Datos*

| **Característica** | **CSV** | **XLS (Heredado)** | **XLSX (Moderno)** |
|---|---|---|---|
| Tipo de archivo | Texto plano | Binario propietario | ZIP / XML comprimido |
| Límite de filas | Ilimitado (según disco/RAM) | 65,536 filas | 1,048,576 filas |
| Límite de columnas | Ilimitado | 256 columnas | 16,384 columnas |
| Múltiples hojas | No (solo 1 tabla) | Sí | Sí |
| Soporte de fórmulas | No (guarda valor | Sí | Sí |

| | | | |
|---|---|---|---|
| | final) | | |
| Formatos y colores | No | Sí | Sí |
| Macros (VBA) | No | Sí | No (requiere .xlsm) |

**¿En qué punto exacto falló la integridad de los datos?**

Falló en la Etapa 2: Transferencia Automatizada. Según el caso expuesto (Kelion, 2020), los laboratorios enviaban correctamente la información en archivos CSV, pero el proceso automático de Public Health England (PHE) importaba dichos archivos CSV a una plantilla obsoleta en formato .XLS. Cuando el acumulado de pruebas superó el límite de 65,536 filas, el sistema ejecutó un truncamiento silencioso: cortó el excedente de información y perdió 15,841 registros sin generar ninguna alerta de error. Con esta acción se rompió gravemente el principio de integridad y trazabilidad del dato.

## Actividad 2: Esquema del Tránsito Seguro de la Información

**Propuesta de Flujo Seguro de Datos**

Para evitar la pérdida de los 15,841 casos, el tránsito seguro de la información debió estructurarse en las siguientes etapas secuenciales:

- 1. Laboratorios (Origen): Generación diaria de resultados en formato CSV (Texto plano sin límite de filas).
- 2. Transferencia Automatizada: Proceso de validación del esquema con control estricto de recuento de filas y verificación de integridad.
- 3. Sistema Central PHE (Consolidación): Carga directa e ingesta nativa en Base de Datos Relacional o archivo XLSX (capacidad de 1,048,576 filas).

- 4. Tablero de Control (Destino): Dashboards gubernamentales (Power BI / Tableau) conectados directamente a la Base de Datos para rastreo de contactos.

**Justificación del Flujo Seguro**

En la fase de laboratorios y transferencia se debe mantener el uso del formato CSV. El CSV representa la alternativa más segura para el origen por no poseer restricciones en el límite de filas, no sufrir corrupción por metadatos o estilos de formato y ser compatible universalmente con cualquier motor de ingesta de datos.

En la fase del sistema central y consolidación está rotundamente prohibido utilizar el formato heredado .XLS debido a su obsolescencia y severa limitación técnica. La consolidación debe realizarse directamente en un motor de bases de datos relacionales garantizando transaccionalidad (ej. verificando que si ingresan 80,000 registros, exactamente 80,000 sean procesados).

Finalmente, si los analistas requieren utilizar hojas de cálculo en la etapa del tablero de control, se debe emplear de manera obligatoria el formato .XLSX (1,048,576 filas), el cual contaba con el soporte suficiente para almacenar el volumen del pico pandémico. No obstante, la arquitectura ideal exige que los tableros de control consuman la información directamente desde la base de datos sin intermediación de hojas electrónicas.

## Actividad 3: Conclusión Analítica sobre Conocimiento Técnico y Ética

El caso de Public Health England demuestra de forma contundente que un descuido técnico en apariencia menor —como desconocer las limitaciones de almacenamiento entre los formatos .XLS y .XLSX— se transforma inmediatamente en un fallo ético con severas

repercusiones en la salud pública. El analista de datos no actúa simplemente como un operador de herramientas ofimáticas; constituye el primer eslabón en la cadena de toma de decisiones estratégicas.

En la situación analizada, las deficiencias en las competencias técnicas de los responsables produjeron distorsiones críticas: los tableros oficiales reflejaron una falsa disminución en la curva de contagios, lo que condujo al gobierno a evaluar erróneamente la efectividad de las restricciones sanitarias. Además, aproximadamente 50,000 contactos estrechos no fueron rastreados oportunamente, acelerando la propagación comunitaria del virus.

La responsabilidad ética del profesional de datos radica en comprender minuciosamente las capacidades y límites de sus herramientas, así como en implementar controles de calidad y validación de integridad. A nivel directivo y gubernamental, la ética exige no fundamentar decisiones de alto impacto en paneles de control que carezcan de auditorías continuas sobre la calidad del dato. Como se documentó en la House of Commons (2020, p. 625), aunque los casos positivos fueron notificados individualmente, el daño en el sistema de rastreo epidemiológico ya se había producido. El rigor técnico no representa un requerimiento opcional, sino un imperativo ético indiscutible cuando la toma de decisiones afecta vidas humanas y políticas de Estado.

## Actividades de Contextualización e Identificación de Conocimientos

### Eje Temático Concertado y Justificación

El equipo de trabajo seleccionó el eje de Seguridad para el desarrollo de la exploración de conjuntos de datos. Esta temática representa un pilar estratégico indispensable fundamentado en tres dimensiones clave:

- Protección y Privacidad: Garantiza el cumplimiento de las normativas de protección de datos personales, asegurando confidencialidad e integridad.
- Calidad y Confiabilidad: Asegura que los conjuntos de información se encuentren libres de manipulaciones, sesgos sistemáticos o inyecciones maliciosas que puedan alterar los modelos analíticos.
- Prevención Proactiva: Permite identificar vectores de riesgo, patrones delictivos y vulnerabilidades latentes antes de que generen afectaciones en la población o en la infraestructura del sistema.

**Clasificación de las Fuentes de Datos**

Para el desarrollo de la presente guía se emplearon fuentes de datos secundarias, específicamente las plataformas Kaggle y Datos Abiertos Bogotá. Se clasifican como secundarias debido a que la recolección original de la información no fue ejecutada directamente por el equipo investigador, sino que proviene de repositorios públicos centralizados estructurados por instituciones oficiales y miembros de la comunidad analítica para su libre consulta.

**Conjuntos de Datos Seleccionados**

- 1. Delitos-Colombia | Portal: Kaggle | Autor: Leonardo Arias Alemán | URL: https://www.kaggle.com/datasets/leonardoariasalemn/delitos-colombia
- 2. Puntos de evaluación de seguridad nocturna para las mujeres. Bogotá D.C. | Portal: Datos Abiertos Bogotá | Autor: Secretaría Distrital de la Mujer | URL: https://datosabiertos.bogota.gov.co/dataset/puntos-de-evaluacion-de-seguridad-nocturna-para-las-mujeres-bogota-d-c-ano-2016

- 3. Rendimiento Académico | Portal: Kaggle | Autor: Marilú Ramírez López | URL: https://www.kaggle.com/datasets/marilramrezlpez/rendimiento-estudiantil

**Clasificación Estadística de Variables**

**Tabla 2**

*Matriz de Clasificación Estadística de Variables Extraídas de los Datasets*

| No. | Variable / Columna | Tipo Estadístico | Subcategoría | Descripción Breve |
|---|---|---|---|---|
| **1** | Iluminación | Cualitativa | Ordinal | Nivel de alumbrado observado (Alta, Media, Baja). |
| **2** | Visibilidad | Cualitativa | Ordinal | Percepción del nivel de visibilidad del entorno. |
| **3** | Presencia de personas | Cuantitativa | Discreta | Conteo del número de personas en el área. |
| **4** | Seguridad | Cualitativa | Ordinal | Nivel estimado de seguridad (Seguro, Inseguro). |
| **5** | Estado del Sendero | Cualitativa | Ordinal | Estado físico del camino peatonal. |
| **6** | Transporte | Cualitativa | Nominal | Tipo de transporte utilizado o disponible. |
| **7** | Presencia mixta | Cualitativa | Nominal | Evaluación de |

| | | | | |
|---|---|---|---|---|
| | | | | diversidad en el sector. |
| **8** | Índice de Seguridad | Cualitativa | Ordinal | Nivel de riesgo o seguridad (Alto, Medio, Bajo). |
| **9** | Dirección | Cualitativa | Nominal | Nomenclatura urbana de la ubicación. |
| **10** | Nombre de localidad | Cualitativa | Nominal | Nombre oficial de la localidad. |
| **11** | Tipo de crimen | Cualitativa | Ordinal | Clasificación según la gravedad del delito. |
| **12** | Delito | Cualitativa | Ordinal | Categorización legal de la infracción. |
| **13** | Tipo de Arma | Cualitativa | Nominal | Elemento utilizado en el delito. |
| **14** | Departamento | Cualitativa | Nominal | Entidad territorial (orden alfabético). |
| **15** | Municipio | Cualitativa | Nominal | Entidad municipal (orden alfabético). |
| **16** | Género | Cualitativa | Nominal | Género de la víctima o registrado. |
| **17** | Rango de edad | Cualitativa | Ordinal | Intervalos categorizados de edad. |
| **18** | Fecha | Cuantitativa | Discreta | Fecha del evento |

| | | | | |
|---|---|---|---|---|
| | | | | expresada numéricamente. |
| **19** | Cantidad | Cuantitativa | Discreta | Número total de casos o registros. |
| **20** | Estudiante | Cuantitativa | Discreta | Identificador o número de estudiante. |
| **21** | Edad | Cuantitativa | Discreta | Edad expresada en años cumplidos. |
| **22** | Nivel de Inglés | Cualitativa | Ordinal | Grado de dominio del idioma. |
| **23** | Horas de Estudio Semana | Cuantitativa | Continua | Tiempo dedicado al estudio semanal. |
| **24** | Asistencia porcentaje | Cuantitativa | Continua | Porcentaje de asistencia registrado. |
| **25** | Participación Actividades | Cualitativa | Nominal | Valor booleano (Verdadero / Falso). |
| **26** | Promedio Calificaciones | Cuantitativa | Continua | Puntaje académico acumulado. |
| **27** | Nivel Estrés | Cualitativa | Ordinal | Grado de estrés (Alto, Medio, Bajo). |
| **28** | Método de Estudio principal | Cualitativa | Nominal | Estrategia de aprendizaje utilizada. |
| **29** | Proyecto final entregado | Cualitativa | Nominal | Estado de entrega |

| | | | | |
|---|---|---|---|---|
| | | | | (Booleano). |
| **30** | Nota Final | Cuantitativa | Continua | Calificación cuantitativa definitiva. |

**Actividades de Apropiación del Conocimiento: Auditoría Técnica**

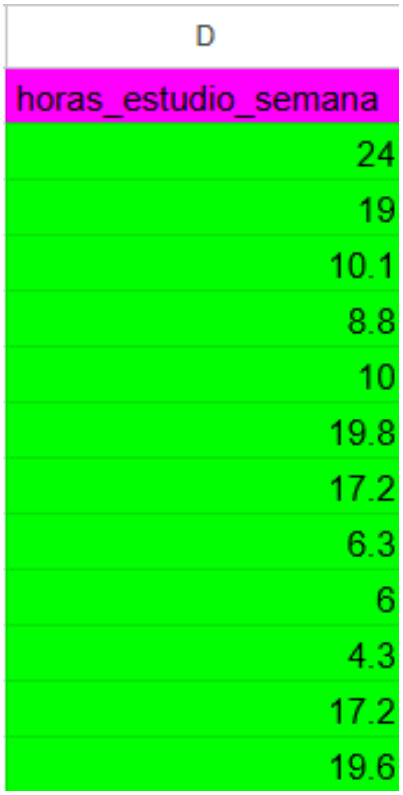
**Dataset 1: Rendimiento Académico (.XLSX)**

***Inconsistencia 1: Ambigüedad en Unidades de Medida y Falta de Estandarización***

- ¿Qué es el problema?: Ambigüedad en la representación de valores continuos dentro de la columna horas_estudio_semana.
- ¿Cómo se detectó?: Mediante la aplicación de filtros sobre la columna, identificando datos enteros mezclados con decimales sin unidad definida.
- ¿Por qué es un problema?: Dificulta la interpretación del dato al no precisar si las fracciones representan minutos o centésimas de hora (ej. 19.6 podría interpretarse erróneamente como 19 horas y 6 minutos en lugar de 19.6 horas).
    - Ejemplo extraído: Valores como 10.1, 8.8, 19.8, 19.6 en el dataset.

**Figura 1.**

*Inconsistencia 1*



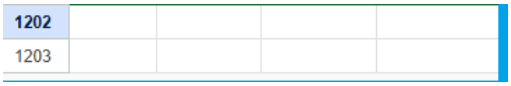
| D |
| --- |
| horas_estudio_semana |
| 24 |
| 19 |
| 10.1 |
| 8.8 |
| 10 |
| 19.8 |
| 17.2 |
| 6.3 |
| 6 |
| 4.3 |
| 17.2 |
| 19.6 |

***Inconsistencia 2: Datos Faltantes (Missing Data) y Problemas de Completitud***

- ¿Qué es el problema?: Presencia de registros nulos y filas vacías intermedias (ej. fila 1202).
- ¿Cómo se detectó?: Mediante inspección visual del total de filas y filtros de celdas en blanco.
- ¿Por qué es un problema?: La conservación de celdas vacías genera desfasajes en las métricas de conteo de estudiantes y produce 'registros huérfanos' que alteran los algoritmos analíticos.
- Ejemplo extraído: Celdas vacías en las filas 1202 y 1203.

***Figura 2.***

*Inconsistencia 2*

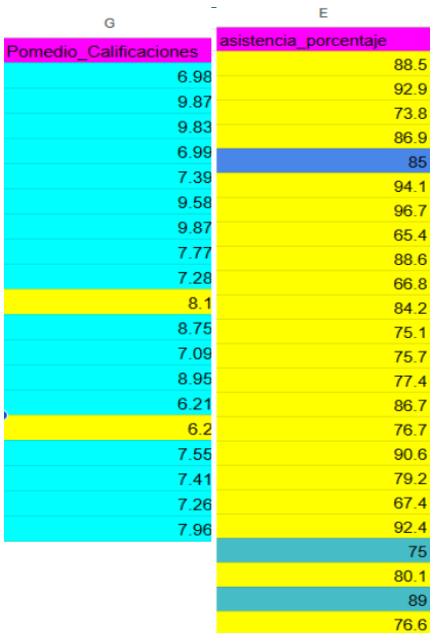



***Inconsistencia 3: Inconsistencia de Formato en Promedios y Porcentajes***

- ¿Qué es el problema?: Disparidad en el número de decimales en las columnas Promedio_Calificaciones y asistencia_porcentaje.
- ¿Cómo se detectó?: Filtrado de columna e inspección visual de los formatos de celda.
- ¿Por qué es un problema?: Impide la estandarización y uniformidad de la información, dificultando la ejecución de scripts automatizados de procesamiento.
- Ejemplo extraído: Mezcla de datos con un decimal (8.1, 6.2) y dos decimales (6.98, 9.87).

***Figura 3.***

*Inconsistencia 3*



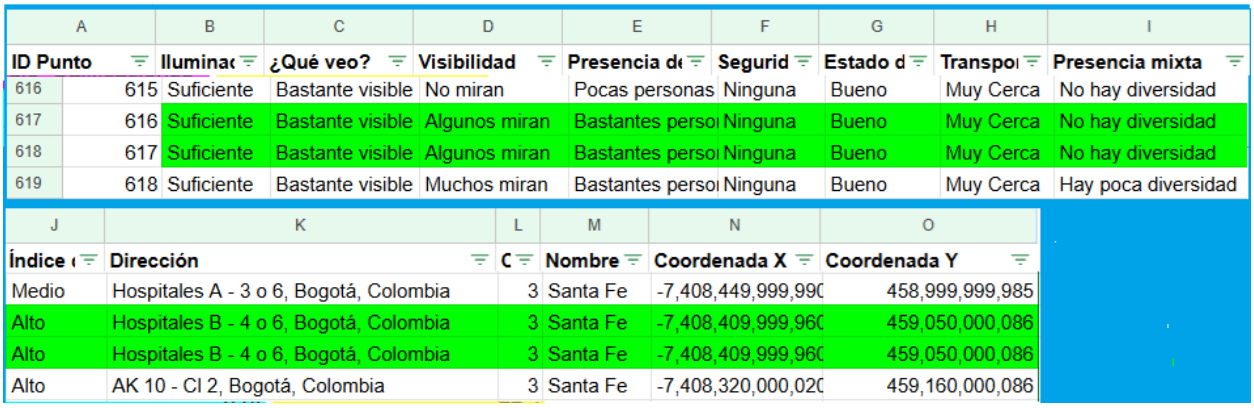
**Dataset 2: Puntos de Evaluación de Seguridad Nocturna (.CSV)**

***Inconsistencia 4: Registros Duplicados (Duplicate Data)***

- ¿Qué es el problema?: Duplicación exacta de filas completas en múltiples variables de localización y evaluación.
- ¿Cómo se detectó?: Filtrado por coincidencia multivariable de ID Punto, Coordenadas y Dirección.
- ¿Por qué es un problema?: Introduce sesgos estadísticos, infla artificialmente la muestra auditada y provoca distorsiones en las consultas a bases de datos.
- Ejemplo extraído: Registros idénticos para ID 616 y 617 en la localidad de Santa Fe con coordenadas coincidentes.

***Figura 4.***

*Inconsistencia 4*



| | A | B | C | D | E | F | G | H | I |
|---|---|---|---|---|---|---|---|---|---|
| | ID Punto | Iluminac | ¿Qué veo? | Visibilidad | Presencia de | Segurid | Estado d | Transpor | Presencia mixta |
| 616 | 615 | Suficiente | Bastante visible | No miran | Pocas personas | Ninguna | Bueno | Muy Cerca | No hay diversidad |
| 617 | 616 | Suficiente | Bastante visible | Algunos miran | Bastantes perso | Ninguna | Bueno | Muy Cerca | No hay diversidad |
| 618 | 617 | Suficiente | Bastante visible | Algunos miran | Bastantes perso | Ninguna | Bueno | Muy Cerca | No hay diversidad |
| 619 | 618 | Suficiente | Bastante visible | Muchos miran | Bastantes perso | Ninguna | Bueno | Muy Cerca | Hay poca diversidad |

| J | K | L | M | N | O |
|---|---|---|---|---|---|
| Índice ( | Dirección | C | Nombre | Coordenada X | Coordenada Y |
| Medio | Hospitales A - 3 o 6, Bogotá, Colombia | 3 | Santa Fe | -7,408,449,999,990 | 458,999,999,985 |
| Alto | Hospitales B - 4 o 6, Bogotá, Colombia | 3 | Santa Fe | -7,408,409,999,960 | 459,050,000,086 |
| Alto | Hospitales B - 4 o 6, Bogotá, Colombia | 3 | Santa Fe | -7,408,409,999,960 | 459,050,000,086 |
| Alto | AK 10 - Cl 2, Bogotá, Colombia | 3 | Santa Fe | -7,408,320,000,020 | 459,160,000,086 |

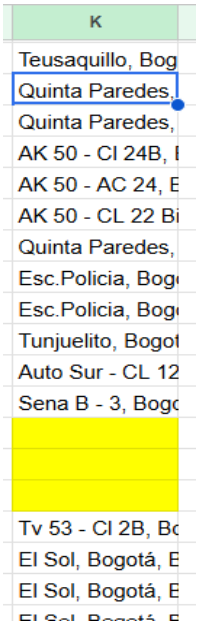
***Inconsistencia 5: Valores Faltantes Esporádicos o Aislados***

- ¿Qué es el problema?: Omisión de información en la variable Dirección dentro de filas que contienen el resto de datos completos.
- ¿Cómo se detectó?: Detección visual y filtrado de nulos en la columna K (Dirección).

- ¿Por qué es un problema?: Interrumpe la ejecución de funciones de aprendizaje automático y causa fallas en modelos de georreferenciación que requieren datos geográficos completos.
- Ejemplo extraído: Tres celdas vacías consecutivas en la columna K rodeadas de registros con direcciones válidas.

***Figura 5.***

*Inconsistencia 5*



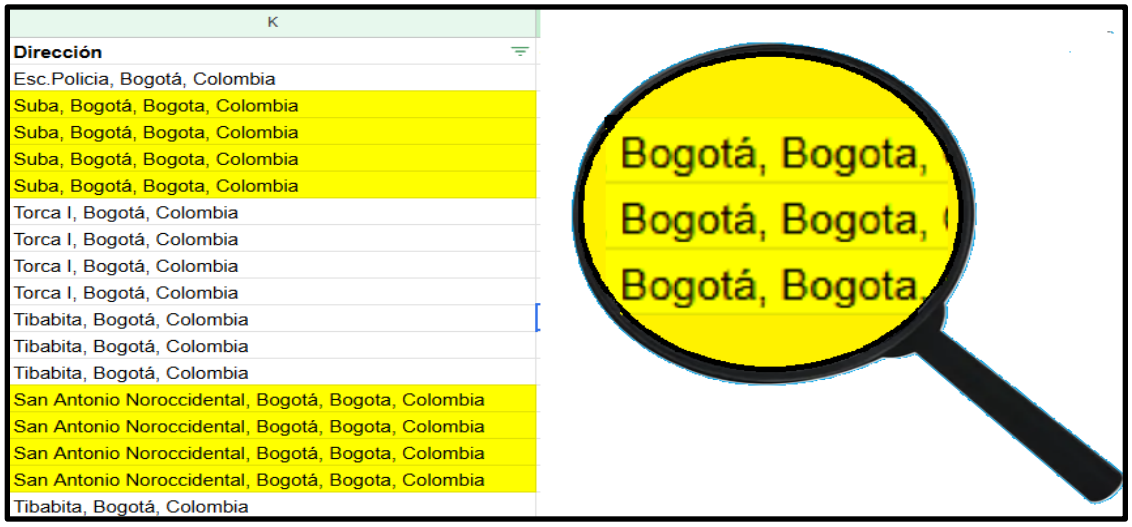

***Inconsistencia 6: Datos Sucios y Redundancia de Cadenas de Texto***

- ¿Qué es el problema?: Cadenas de texto con redundancias ('Bogotá, Bogotá'), faltas de ortografía y presencia de tildes o caracteres especiales.
- ¿Cómo se detectó?: Filtrado alfabético e inspección visual de la variable Dirección.
- ¿Por me es un problema?: Provoca errores de sintaxis y fallos de codificación durante la ingesta de datos en Python, SQL o MySQL al no procesar adecuadamente caracteres especiales.

- Ejemplo extraído: Cadenas formateadas como 'Suba, Bogotá, Bogotá, Colombia' o 'San Antonio Noroccidental, Bogotá, Bogotá, Colombia'.

***Figura 6.***

*Inconsistencia 6*




## Actividades de Transferencia de Conocimiento: Diccionario de Datos

Se seleccionó el dataset de Puntos de Evaluación de Seguridad Nocturna para las Mujeres por ser la estructura más robusta y completa. A continuación se presenta la documentación técnica mediante el instrumento de metadatos:

**Tabla 3**

*Diccionario de Datos del Dataset de Seguridad Nocturna*

| Nombre Original | Nombre Sugerido | Clasificación Estad. | Tipo Técnico | Descripción Semántica | Formato / Valores |
|---|---|---|---|---|---|
| ID Punto | id_punto | Cuantitativa Discreta | Entero | Identificador único asignado al punto de evaluación. | Número entero |

| | | | | | |
|---|---|---|---|---|---|
| Iluminación | iluminacion | Cualitativa Ordinal | Cadena texto | Grado de alumbrado público observado. | Brillante, Suficiente, Insuficiente, Oscuro |
| ¿Que veo? | que_veo | Cualitativa Ordinal | Cadena texto | Grado de visibilidad panorámica percibida. | Visibilidad total, Bastante visible, Poco visible |
| Visibilidad | visibilidad | Cualitativa Ordinal | Cadena texto | Percepción de personas atentas al entorno. | Muchos miran, Algunos miran, No miran |
| Presencia personas | presencia_personas | Cualitativa Ordinal | Cadena texto | Afluencia de peatones en el sector. | Bastantes personas, Pocas personas, Desierto |
| Seguridad | seguridad | Cualitativa Ordinal | Cadena texto | Percepción de vigilancia institucional. | Alta, Media, Baja, Ninguna |
| Estado del Sendero | estado_sendero | Cualitativa Ordinal | Cadena texto | Condición física de la vía peatonal. | Bueno, Regular, Malo |
| Transporte | transporte | Cualitativa Nominal | Cadena texto | Cercanía de paraderos de transporte. | Muy cerca, Cerca, Lejos, No disponible |
| Presencia mixta | presencia_mixta | Cualitativa Nominal | Cadena texto | Diversidad de género/edad en el espacio. | Hay diversidad, Poca diversidad, No hay |

| | | | | | |
|---|---|---|---|---|---|
| Índice Seguridad | indice_seguridad | Cualitativa Ordinal | Cadena texto | Valoración global del nivel de riesgo. | Alto, Medio, Bajo |
| Dirección | direccion | Cualitativa Nominal | Cadena texto | Ubicación o nomenclatura urbana. | Texto alfanumérico |
| Nombre Localidad | nombre_localidad | Cualitativa Nominal | Cadena texto | Nombre de la localidad oficial. | Texto (Nombre propio) |
| Código Localidad | codigo_localidad | Cuantitativa Discreta | Entero | Código numérico político-administrativo. | Número entero (1 a 20) |
| Coordenada X | coordenada_x | Cuantitativa Continua | Decimal | Posición geográfica longitudinal. | Coordenadas planas (Metros) |
| Coordenada Y | coordenada_y | Cuantitativa Continua | Decimal | Posición geográfica latitudinal. | Coordenadas planas (Metros) |

## Referencias

Arias Alemán, L. (s. f.). Delitos-Colombia [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/leonardoariasalemn/delitos-colombia

Datos Abiertos Bogotá. (s. f.). Portal de Datos Abiertos de la Ciudad de Bogotá D.C. https://datosabiertos.bogota.gov.co/

Datos Abiertos Colombia. (s. f.). Portal Único de Datos Abiertos del Estado Colombiano. https://www.datos.gov.co/

Kaggle. (s. f.). Data Science and Machine Learning Community Platform. https://www.kaggle.com/

Kelion, L. (2020, 5 de octubre). Excel: Why using an old format caused 15,841 COVID tests to be lost. BBC News. https://www.bbc.com/news/technology-54423988

Ramírez López, M. (s. f.). Rendimiento Académico [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/marilramrezlpez/rendimiento-estudiantil

Secretaría Distrital de la Mujer. (2016). Puntos de evaluación de seguridad nocturna para las mujeres. Bogotá D.C. [Conjunto de datos]. Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/puntos-de-evaluacion-de-seguridad-nocturna-para-las-mujeres-bogota-d-c-ano-2016